Escuela de Doctorado
y Estudios de Posgrado
Universidad de La Laguna

PROYECTO DATA ANALYSIS

Informática Industrial Avanzada

Jolehisy Acevedo Medina

24/04/2026

Máster en Ingeniería Industrial

Universidad de La Laguna

ÍNDICE

1. Introducción 3
1.1. Contexto y Justificación del Proyecto 3
1.2. Descripción del Dataset 3
1.3. Objetivos y Metodología 4
2. Análisis Exploratorio de Datos (EDA) 4
2.1. Análisis Estadístico Descriptivo 4
2.2. Distribución de las Características Químicas 6
3. Análisis Bivariado y Correlaciones 8
3.1. Análisis Global de Características vs. Calidad 8
3.2. Análisis de Correlación y Multicolinealidad 10
4. Preprocesamiento y Limpieza de Datos 11
4.1. Tratamiento de Valores Faltantes y Duplicados 11
4.2. Transformación Logarítmica 12
4.3. Normalización de los Datos 13
4.4. Relaciones Matemáticas sobre Datos Normalizados 13
5. Análisis de Componentes Principales (PCA) 14
5.1. Selección de Componentes (Criterio del 95% de Varianza) 14
5.2. Interpretación de las Componentes (Loadings) 15
5.3. Transformación Definitiva al Espacio Reducido 15
6. Modelado Predictivo y Clasificación 17
6.1. Metodología de Entrenamiento y Evaluación 17
6.2. Modelo con PCA (Entreno único 80/20) 17
6.3. Validación Cruzada con PCA (5-Folds) 19
6.4. Evaluación de Modelos con el Dataset Original (Entreno único 80/20) 20
6.5. Evaluación de Modelos con el Dataset Original (5-Fold Cross-Validation) 21
7. Tratamiento del Desbalanceo (SMOTE) 22
8. Conclusión General del Proyecto 24

1. Introducción

1.1. Contexto y Justificación del Proyecto

La evaluación de la calidad del vino ha dependido tradicionalmente de catas sensoriales realizadas por expertos humanos. Aunque valioso, este proceso es inherentemente subjetivo, costoso y difícil de escalar en grandes producciones industriales. El presente proyecto nace con el objetivo de objetivizar este proceso aplicando técnicas de aprendizaje automático (*Machine Learning*).

El reto fundamental consiste en desarrollar un sistema capaz de predecir la calificación sensorial de un vino basándose exclusivamente en su huella química. Para ello, se abordará el problema desde una perspectiva de clasificación multiclase, enfrentándonos a desafíos como son la alta dimensionalidad, la colinealidad entre variables y el desbalanceo de las clases.

1.2. Descripción del Dataset

Para llevar a cabo este análisis predictivo, se ha utilizado el conjunto de datos **"Wine Quality"**, el cual recopila información fisicoquímica de miles de muestras de las variantes de vino tinto y blanco del *Vinho Verde* portugués.

El conjunto de datos está compuesto por variables de entrada continuas (características químicas) y una variable objetivo discreta. Las características químicas analizadas son:

- **Ácidos orgánicos:** Acidez fija (*Fixed acidity*), acidez volátil (*Volatile acidity*) y ácido cítrico (*Citric acid*), responsables de la frescura, el sabor y la estabilidad microbiológica.
- **Azúcar residual (*Residual sugar*):** Azúcar remanente tras la fermentación, factor determinante para el dulzor.
- **Cloruros (*Chlorides*):** Concentración de sales presentes en la muestra.
- **Dióxido de azufre (*Free / Total sulfur dioxide*):** Conservante utilizado para prevenir la oxidación y el crecimiento bacteriano.
- **Parámetros físicos y antioxidantes:** Densidad (*Density*), nivel de acidez (*pH*) y sulfatos (*Sulphates*).
- **Alcohol:** Graduación alcohólica, uno de los factores con mayor peso histórico en la percepción de calidad.

La variable a predecir (**Target**) es la **Calidad (*Quality*)**, representada por una puntuación numérica (de 0 a 10) otorgada por catadores profesionales, la cual refleja la excelencia global percibida del vino.

1.3. Objetivos y Metodología

Para resolver este problema, el proyecto se ha estructurado con los siguientes objetivos específicos:

1. **Análisis Exploratorio de Datos (EDA):** Realizar un estudio de las estadísticas descriptivas y evaluar la matriz de correlación para identificar la relación lineal subyacente entre los parámetros químicos y la calidad final, prestando especial atención a la distribución de las características.
2. **Preprocesamiento y Limpieza:** Garantizar la integridad de los datos gestionando posibles valores nulos y, de manera crítica, aplicar una normalización de características (*StandardScaler*).
3. **Reducción de Dimensionalidad (PCA):** Dado que nuestras características químicas son variables continuas, estas pueden representarse algebraicamente como vectores en un espacio multidimensional. Aprovechando esta representación y la relación lineal entre ellas, implementaremos el **Análisis de Componentes Principales (PCA)** para rotar y proyectar este espacio en uno de menor dimensión (reteniendo el 95% de la varianza), eliminando la colinealidad y el ruido sin perder la estructura fundamental de los datos.
4. **Clasificación Probabilística:** Entrenar dos algoritmos de clasificación paramétrica y probabilística: *Linear Discriminant Analysis (LDA)* y *Gaussian Naïve Bayes*.
5. **Evaluación Rigurosa y Comparativa:** Contrastar el rendimiento empírico de ambos modelos con y sin el uso del PCA para determinar el impacto real de la reducción de dimensionalidad. Esta evaluación se llevará a cabo mediante Matrices de Confusión y Validación Cruzada (*Cross-Validation*), garantizando que las métricas finales sean robustas y libres de sesgos estadísticos.

2. Análisis Exploratorio de Datos (EDA)

Como fase inicial de nuestro estudio, resulta indispensable comprender la naturaleza, distribución y posibles anomalías de las características fisicoquímicas con las que vamos a trabajar. Este análisis exploratorio (EDA) guiará las decisiones metodológicas posteriores, especialmente en las fases de preprocesamiento y modelado.

2.1. Análisis Estadístico Descriptivo

El primer paso para conocer la "forma" matemática de nuestro conjunto de datos es observar sus estadísticas vitales. Evaluando los rangos, las medias y la dispersión (desviación estándar) de cada característica, podemos obtener una primera pista sobre si nuestras variables operan en magnitudes compatibles o si requerirán transformaciones previas.

	mean	std	min	50%	max
fixed acidity	7.215179	1.319671	3.80000	7.00000	15.90000
volatile acidity	0.344130	0.168248	0.08000	0.30000	1.58000
citric acid	0.318494	0.147157	0.00000	0.31000	1.66000
residual sugar	5.048477	4.500180	0.60000	2.70000	65.80000
chlorides	0.056690	0.036863	0.00900	0.04700	0.61100
free sulfur dioxide	30.036654	17.805045	1.00000	28.00000	289.00000
total sulfur dioxide	114.109023	56.774223	6.00000	116.00000	440.00000
density	0.994535	0.002966	0.98711	0.99465	1.03898
pH	3.224664	0.160379	2.72000	3.21000	4.01000
sulphates	0.533357	0.149743	0.22000	0.51000	2.00000
alcohol	10.549241	1.185933	8.00000	10.40000	14.90000
quality	5.795677	0.879772	3.00000	6.00000	9.00000
type	0.255451	0.436155	0.00000	0.00000	1.00000

Figura 1. Tabla de estadísticas descriptivas del dataset

Tras observar las métricas centrales y de dispersión generadas en nuestro cuaderno de trabajo, extraemos tres conclusiones analíticas fundamentales que justifican nuestras siguientes acciones en el proyecto:

1. Heterogeneidad de Escalas: Las variables químicas operan en magnitudes completamente distintas. Por ejemplo, la variable density fluctúa en un rango milimétrico (0.987 a 1.038), mientras que el total sulfur dioxide presenta una media de 114 y picos de hasta 440.

- *¿Por qué es esto un problema?* Porque algoritmos como PCA se basan en el cálculo de varianzas; sin escalado previo, el azufre dominaría el modelo simplemente por tener valores absolutos más grandes

2. Detección de Valores Atípicos (Outliers): Contrastando la mediana con el valor máximo, observamos asimetrías extremas (ej. el azúcar residual tiene una mediana de 2.7 y un máximo de 65.8).

- *¿Por qué es relevante?* Esto demuestra la existencia de vinos con perfiles químicos anómalos que introducen ruido en el dataset, justificando la necesidad de aplicar una reducción de dimensionalidad posterior.

3. Perfil de la Variable Objetivo (quality): La media y la mediana de la calidad se sitúan casi exactamente en 6.

- *¿Por qué supone un problema algorítmico?* Porque confirma un severo desbalanceo. Al haber una inmensa mayoría de vinos de calidad media y escasez de ejemplos excelentes o deficientes, los clasificadores probabilísticos tenderán irremediablemente a sesgar sus predicciones hacia la clase mayoritaria.

2.2. Distribución de las Características Químicas

Para complementar las métricas numéricas, analizamos visualmente la distribución de las 11 variables químicas originales mediante histogramas. El objetivo es identificar asimetrías, comportamientos no lineales y confirmar la presencia de valores atípicos.

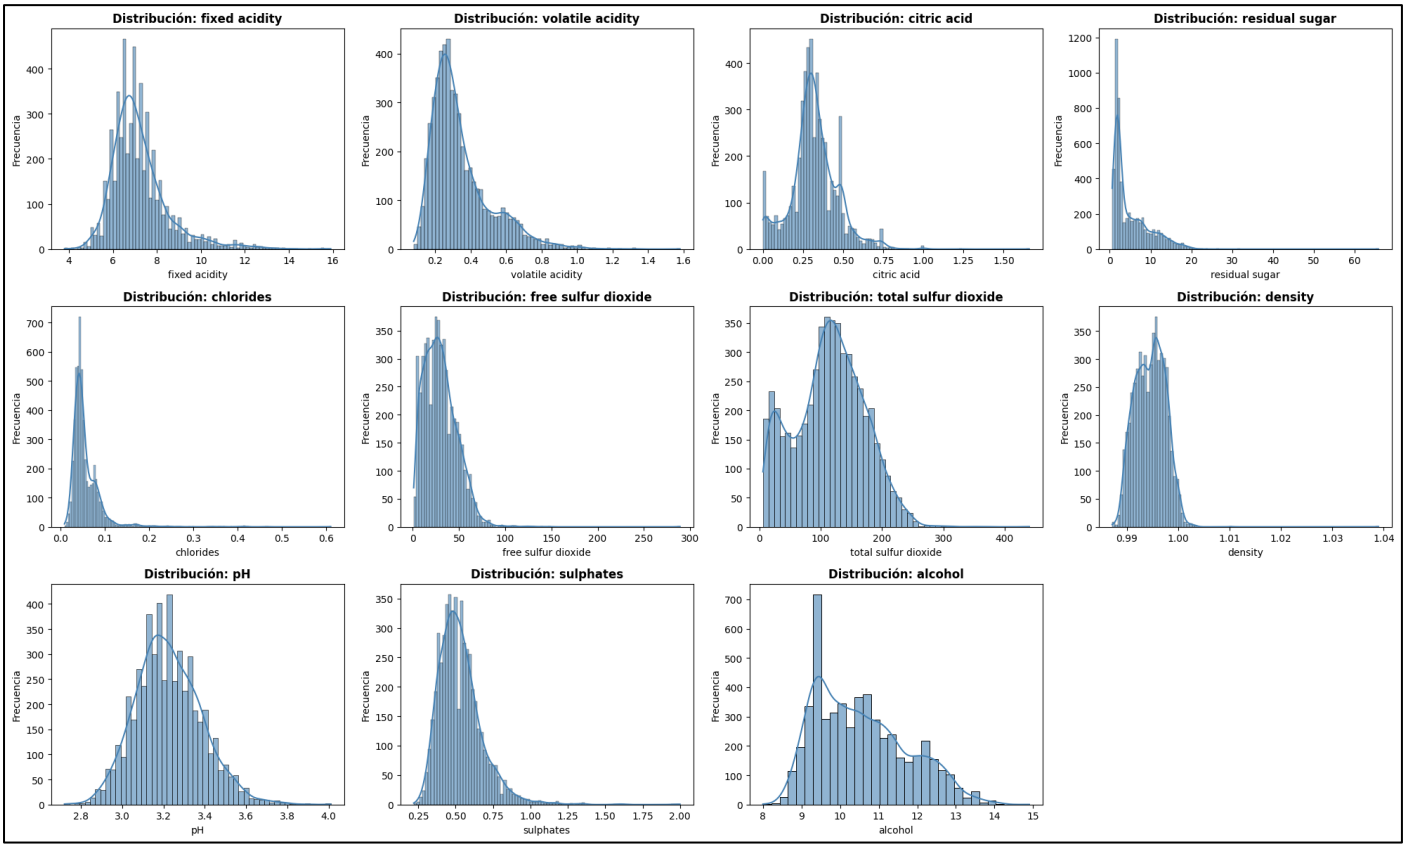

Figura 2. Distribución de frecuencias de las características fisicoquímicas del dataset.

Del análisis visual de estas gráficas, extraemos cuatro conclusiones fundamentales:

1. Normalidad en variables físicas: Características como la density y el pH presentan distribuciones perfectamente simétricas (Campana de Gauss).

- *¿Por qué es relevante?* Porque indica que la base estructural de los vinos es muy homogénea, lo cual es ideal para algoritmos probabilísticos como Naïve Bayes, que asumen distribuciones normales en los datos subyacentes.

2. Asimetría positiva severa (Outliers): Variables como el residual sugar, chlorides y el sulfur dioxide concentran sus datos a la izquierda, proyectando largas "colas" hacia la derecha.

- *¿Por qué ocurre?* Demuestra visualmente la presencia de valores atípicos reales (vinos con dosis extremas de conservantes o azúcar). Esta dispersión justifica la futura aplicación del PCA para reducir el impacto de este ruido en los modelos predictivos.

3. Multimodalidad anómala: El citric acid no dibuja una curva natural, sino que presenta múltiples picos definidos (destacando uno en el 0.0 y otro cercano al 0.5).

- *¿Por qué es importante?* Porque esto rompe la aleatoriedad continua de las variables.

4. Ratificación visual de escalas: Los márgenes de los ejes horizontales (X) muestran rangos matemáticamente incompatibles.

- *¿Por qué lo destacamos?* Porque observar un eje que abarca 0.02 unidades (densidad) junto a otro que abarca 400 (azufre) consolida y justifica de forma ineludible la aplicación de un escalado de datos (*StandardScaler*) como paso previo a cualquier modelado.

2.3. Distribución de la Variable Objetivo (Calidad)

Para finalizar el análisis exploratorio, aislamos y analizamos la variable que nuestros modelos intentarán predecir (quality). El objetivo es evaluar la proporción exacta de sus clases y anticipar posibles sesgos estructurales antes de la fase de modelado.

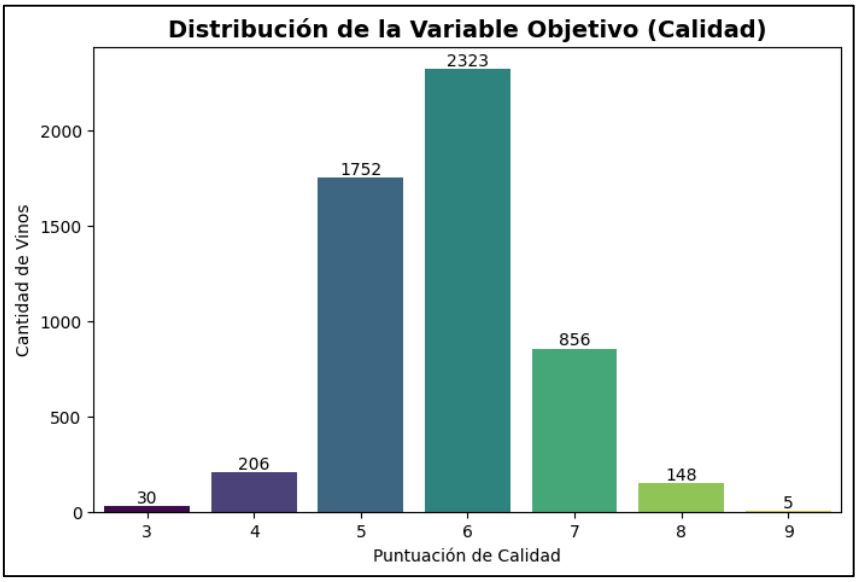

Figura 3. Distribución de frecuencias de la variable objetivo (Calidad).

De la visualización de esta variable, extraemos las siguientes conclusiones para el diseño del algoritmo:

1. Predominio masivo de calidades medias: Las puntuaciones 5 y 6 agrupan la inmensa mayoría de las muestras (1,752 y 2,323 vinos, respectivamente, representando aproximadamente el 76% del dataset).

- *¿Por qué es crítico?* Porque confirma matemáticamente un **desbalanceo severo** de las clases, indicando que el conjunto de datos no representa la calidad del vino de forma equitativa.

2. Escasez de vinos extremos: Las calidades excepcionales o deficientes son estadísticamente marginales (por ejemplo, solo existen 5 muestras de calidad 9 y 30 muestras de calidad 3).

- *¿Por qué supone un problema algorítmico?* Al carecer de un volumen suficiente de ejemplos en los extremos, los modelos probabilísticos no dispondrán de información estadísticamente significativa para aprender a diferenciar los patrones químicos de un vino excepcional.

3. Riesgo inminente de sesgo predictivo: La distribución en forma de "campana" fuertemente centralizada condicionará el comportamiento de la predicción.

- *¿Por qué afectará a los resultados?* Porque cualquier clasificador estándar (como LDA o Naïve Bayes), ante la incertidumbre matemática, tenderá a apostar siempre por las calidades 5 y 6 para maximizar su precisión global (*Accuracy*), ignorando a las clases minoritarias.

3. Análisis Bivariado y Correlaciones

Tras analizar las variables de forma individual, el siguiente paso es comprender cómo interactúan entre sí y, lo más importante, cómo influyen matemáticamente en la valoración final del vino.

3.1. Análisis Global de Características vs. Calidad

Utilizamos diagramas de caja (*Boxplots*) para evaluar cómo fluctúa la distribución y dispersión de cada componente químico a medida que aumenta la puntuación de calidad del vino.

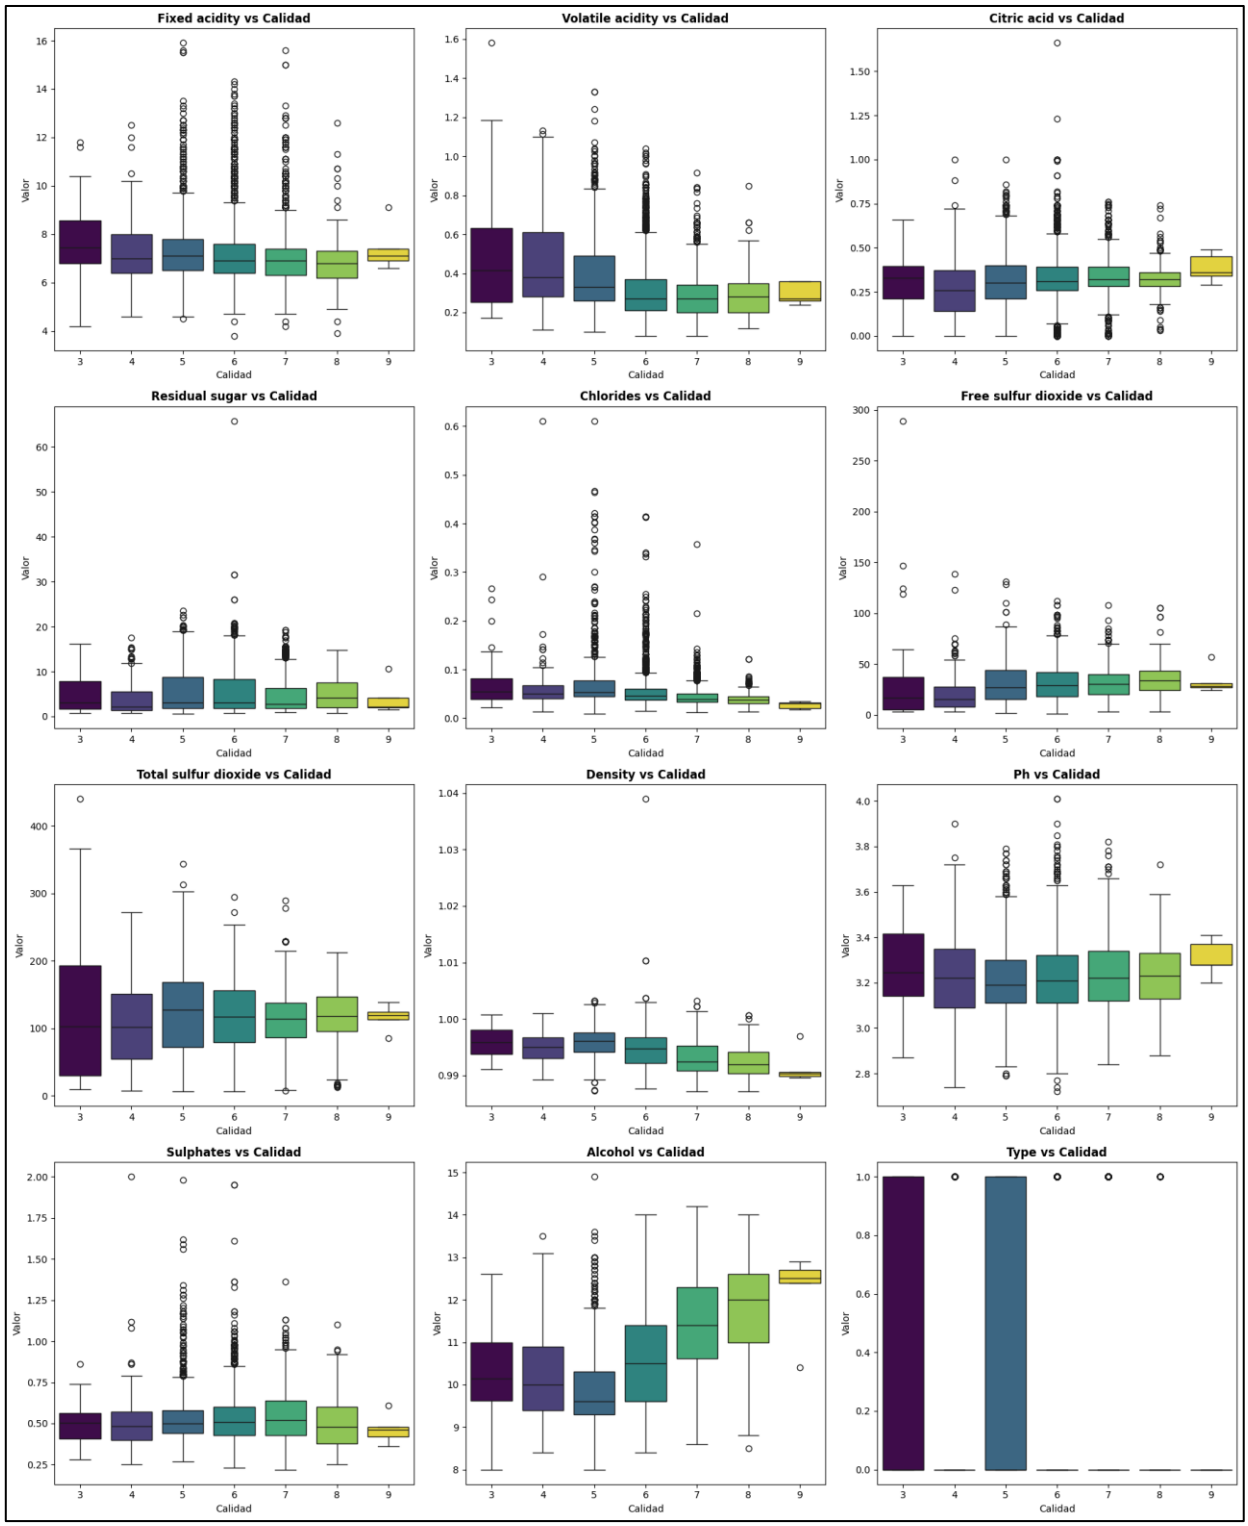

Figura 4. Diagramas de caja de las características fisicoquímicas segmentadas por calidad.

De esta visualización extraemos tres patrones clave para la predicción:

1. Determinantes principales (Alcohol y Acidez Volátil): A mayor nivel de alcohol y menor acidez volátil, mayor es la calidad del vino.

2. Variables secundarias (Densidad, Cloruros y Azúcar): Estas variables tienden a disminuir en los vinos de las categorías más altas.

3. Variables de bajo impacto (pH, Ácido Cítrico, Sulfatos): Sus medianas y cajas se mantienen prácticamente estáticas en todas las calidades.

3.2. Análisis de Correlación y Multicolinealidad

Para optimizar el proceso de clasificación, cuantificamos las dependencias lineales entre todas las dimensiones del dataset mediante una matriz de correlación.

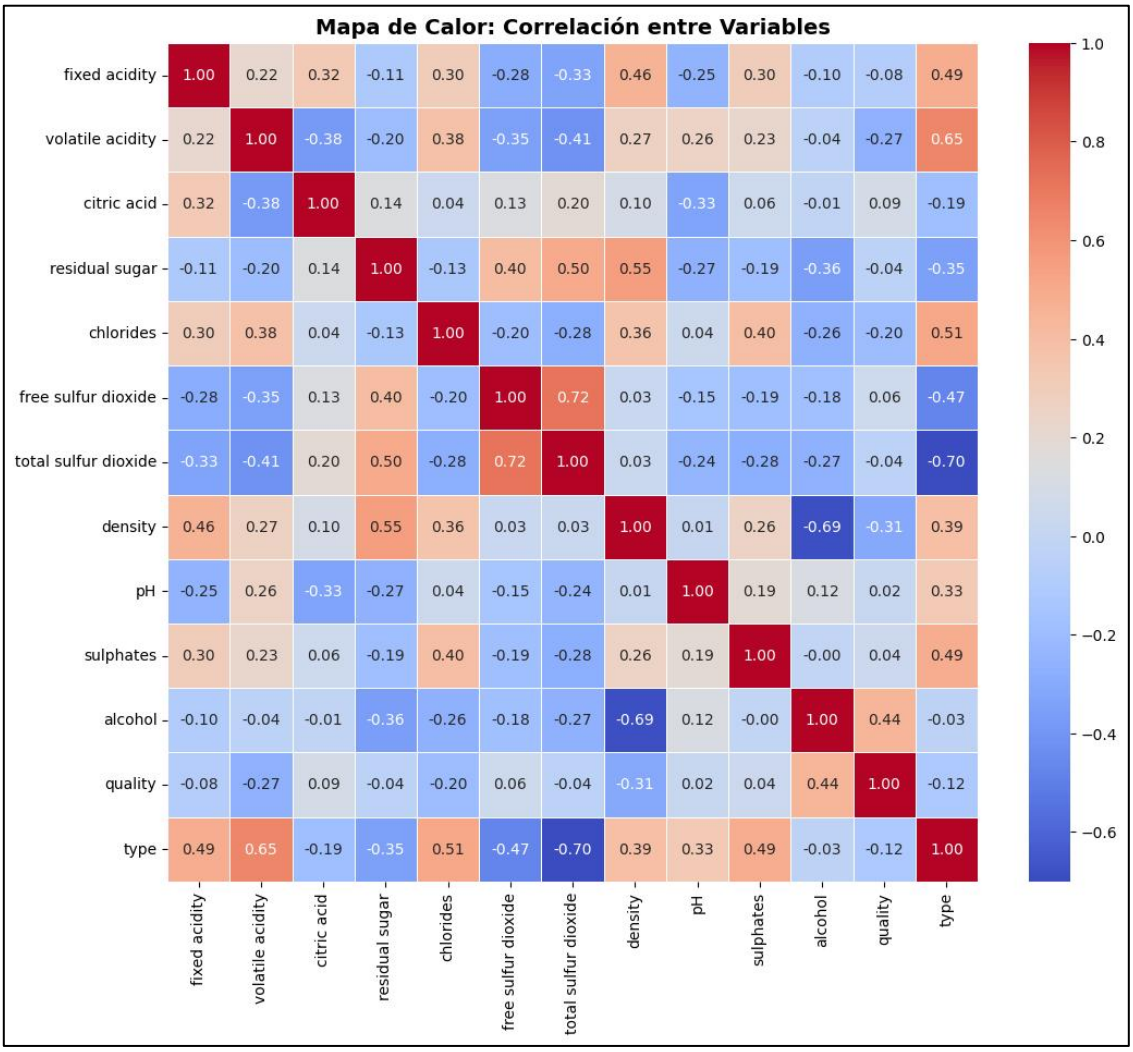

Figura 5. Mapa de calor de correlaciones lineales.

La matriz revela las siguientes interacciones estructurales:

1. Confirmación de capacidad predictiva: Se ratifica matemáticamente que el alcohol (+0.44) presenta la correlación positiva más fuerte con la calidad, seguido de tendencias negativas en la densidad (-0.31) y la acidez volátil (-0.27).

2. Alta Redundancia Informativa: Observamos correlaciones muy elevadas entre pares de variables de entrada, destacando el dióxido de azufre libre vs. total (+0.72) y la densidad vs. alcohol (-0.69).

- *¿Por qué es un problema?* La multicolinealidad confunde gravemente a modelos como el *Naïve Bayes*, el cual asume de forma nativa que todas las variables son 100% independientes entre sí.

3. Justificación Definitiva del PCA: El dataset contiene variables altamente correlacionadas y variables que apenas impactan en el objetivo. El Análisis de Componentes Principales aprovechará exactamente estas dependencias lineales para fusionar las variables redundantes, comprimiendo el espacio de datos sin perder su esencia predictiva.

4. Preprocesamiento y Limpieza de Datos

Para garantizar la fiabilidad del Análisis de Componentes Principales (PCA) y de los posteriores modelos probabilísticos, es imperativo someter el dataset a un proceso de limpieza y estandarización matemática.

4.1. Tratamiento de Valores Faltantes y Duplicados

Se evaluó la integridad estructural del dataset mediante un recuento de valores nulos y una búsqueda de registros idénticos.

```
--- RECUENTO DE VALORES NULOS ---

fixed acidity           0
volatile acidity        0
citric acid             0
residual sugar          0
chlorides               0
free sulfur dioxide     0
total sulfur dioxide    0
density                 0
pH                      0
sulphates               0
alcohol                 0
quality                 0
type                    0
dtype: int64

Total de valores faltantes en el dataset: 0
El dataset está completo. No se requiere imputación inmediata.

--- RECUENTO DE VALORES DUPLICADOS ---
Registros duplicados detectados: 1177

np.int64(1177)

Registros duplicados después de eliminar: 0

np.int64(0)
```

Figura 6. Recuento de valores nulos y duplicados.

De este diagnóstico y su posterior tratamiento, destacamos dos acciones:

1. Ausencia total de valores nulos: El recuento arrojó 0 nulos en la totalidad de las características, por lo que se descartó el uso de técnicas de imputación (como rellenado por media o KNN).

2. Eliminación de registros duplicados: Se identificaron y borraron filas que contenían exactamente los mismos valores en todas sus dimensiones.

Aquí tienes el contenido para el apartado **4.2** de tu informe, redactado con un estilo profesional y académico, listo para copiar y pegar directamente en tu archivo de Word:

4.2. Transformación Logarítmica

Tras el análisis exploratorio (EDA), se identificó que la mayoría de las variables fisicoquímicas presentan una distribución asimétrica positiva (colas largas hacia la derecha). Los modelos probabilísticos paramétricos que se emplearán en este estudio (LDA y Naïve Bayes) asumen que las variables de entrada siguen una distribución normal o gaussiana. Para corregir la asimetría y "acortar" las colas de las distribuciones, se aplicó una transformación matemática de tipo log(1+x). Esta función es especialmente útil en este conjunto de datos, ya que permite tratar valores cercanos a cero (como ocurre en el ácido cítrico) sin generar errores matemáticos. Esto hace que:

- **Simetría:** Reduce el sesgo de las variables, centrando la masa de los datos y aproximándola a una campana de Gauss.
- **Estabilización de la varianza:** Comprime el rango de los valores atípicos, evitando que estos distorsionen excesivamente las fronteras de decisión de los modelos lineales.

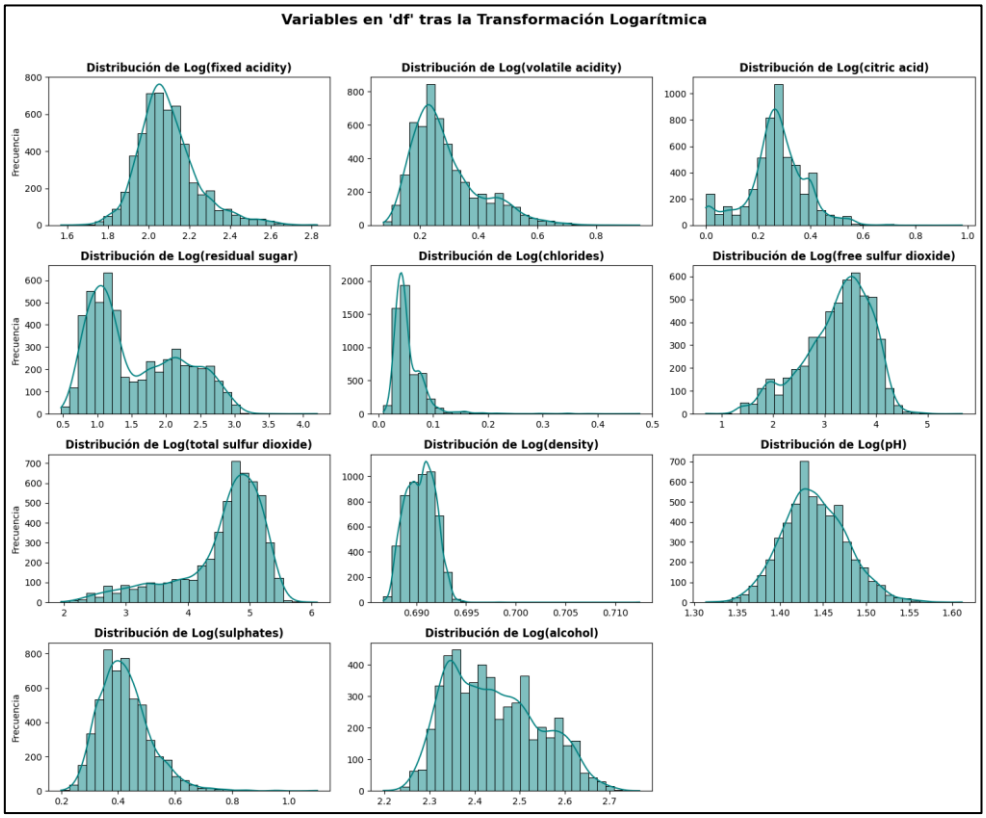

Figura 7. Variables tras aplicar la transformación logarítmica.

4.3. Normalización de los Datos

Aplicamos el algoritmo StandardScaler a todas las variables fisicoquímicas, transformando su distribución original para forzar una **media de 0 y una desviación típica de 1**.

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	type
0	0.140064	2.115349	-2.164515	-0.699699	0.523880	-1.069272	-1.411143	1.100996	1.779304	0.177941	-0.969152	1
1	0.443199	3.185297	-2.164515	-0.544135	1.120736	-0.282905	-0.829839	0.763753	-0.153797	0.979389	-0.631833	1
2	0.443199	2.471998	-1.892672	-0.610806	0.957957	-0.844596	-1.058837	0.831202	0.220351	0.779027	-0.631833	1
3	3.019841	-0.381197	1.641293	-0.699699	0.496751	-0.732258	-0.953146	1.168444	-0.403229	0.311515	-0.631833	1
4	0.140064	1.877583	-2.164515	-0.721923	0.496751	-0.956934	-1.305451	1.100996	1.779304	0.177941	-0.969152	1

Figura 8. Tabla con 5 filas aleatorias de datos estandarizados.

Ahora todas las mediciones (desde los miligramos hasta los grados de alcohol) han perdido sus unidades y operan ahora en una escala puramente relativa.

4.4. Relaciones Matemáticas sobre Datos Normalizados

Con los datos ya estandarizados, realizamos una última validación visual para observar las dependencias químicas puras, libres de las distorsiones de sus escalas originales.

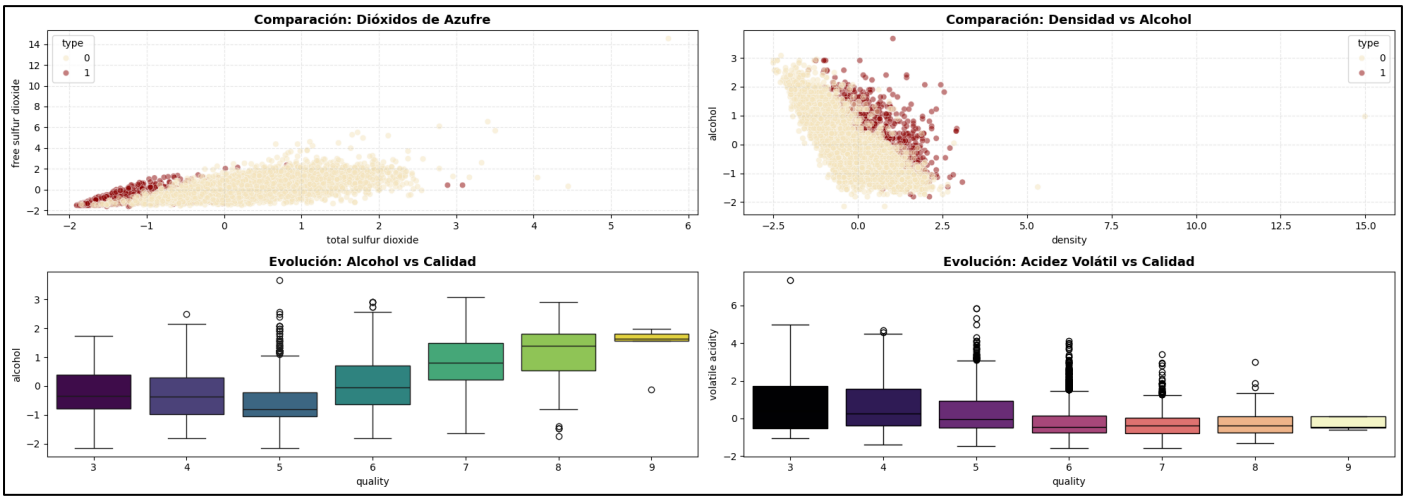

Figura 9. Dispersión y evolución de las características químicas estandarizadas.

De la observación conjunta de este panel, extraemos las validaciones previas al modelado:

1. Sincronía Lineal: Se observan alineaciones diagonales casi perfectas (Dióxidos de Azufre) y dispersiones inversas muy claras (Densidad vs Alcohol).

2. Separación Relativa de Clases (Boxplots): En relación con la marca central (valor 0), el alcohol asciende progresivamente en las calidades altas, mientras que la acidez volátil desciende hacia los valores negativos.

5. Análisis de Componentes Principales (PCA)

El objetivo de esta fase es reducir la complejidad computacional y la redundancia informativa del dataset. El PCA nos permite transformar el espacio de 12 variables químicas en un nuevo sistema de coordenadas ortogonales (Componentes Principales o PC), logrando una simplificación dimensional sin perder la varianza estructural de los datos.

5.1. Selección de Componentes (Criterio del 95% de Varianza)

Aplicamos el algoritmo PCA y evaluamos la varianza explicada por cada nueva componente para determinar el punto óptimo de corte.

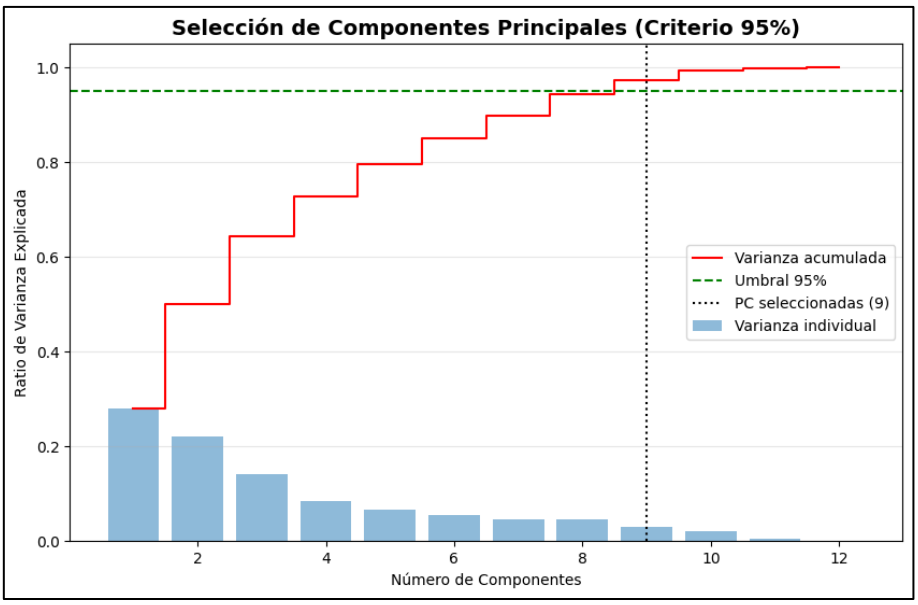

Figura 10. Varianza explicada individual y acumulada por número de componentes.

Del análisis de la curva de varianza, extraemos las siguientes conclusiones:

1. Punto de Saturación Óptimo (9 Componentes): El umbral crítico del 95% de la varianza explicada se alcanza exactamente al retener las primeras 9 componentes principales. Esto demuestra que podemos descartar las 3 dimensiones restantes (que solo aportan un 5% de varianza residual o "ruido"), logrando un dataset un 25% más ligero sin sacrificar poder predictivo.

2. Complejidad inherente del sistema: Las dos primeras componentes (PC1 y PC2) capturan aproximadamente el 50% de la varianza total. Esto evidencia que la química del vino es un sistema altamente multidimensional; a diferencia de problemas más simples, aquí no basta con 2 o 3 variables para capturar los matices que definen la excelencia de una muestra.

5.2. Interpretación de las Componentes (Loadings)

Para comprender qué información química ha comprimido el PCA dentro de cada nueva dimensión abstracta, analizamos la matriz de *loadings* (cargas).

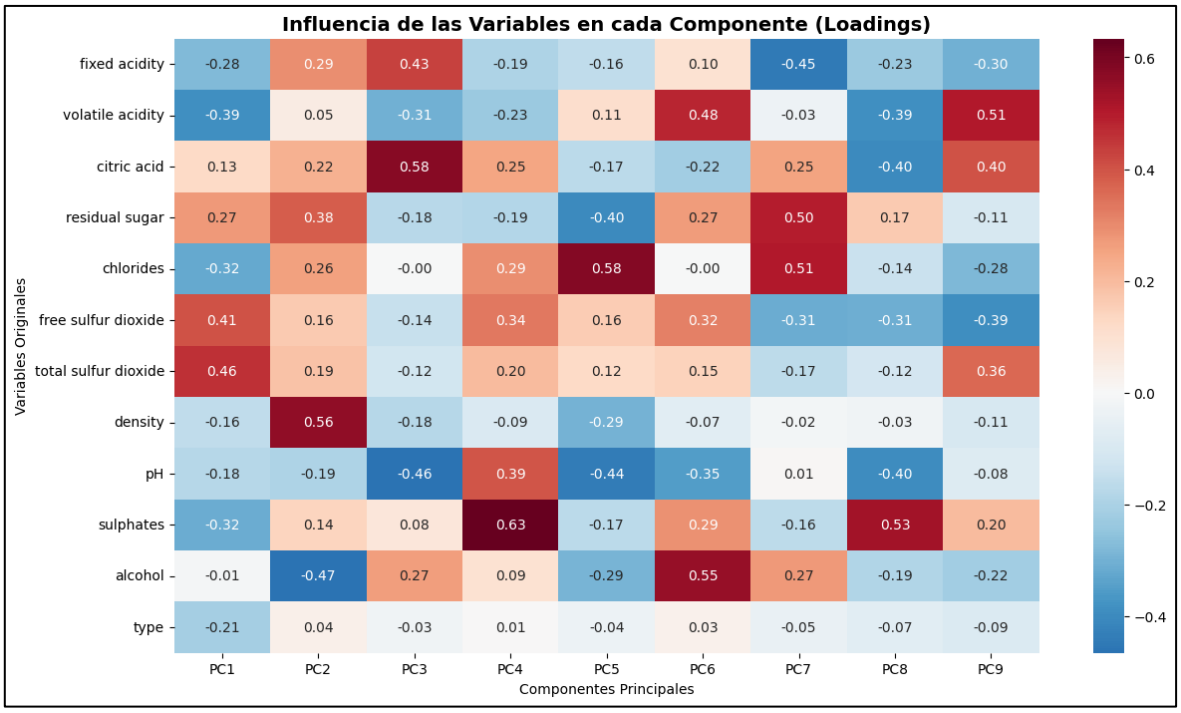

Figura 11. Mapa de calor de las influencias (Loadings) de las variables originales sobre cada Componente Principal.

Este análisis nos confirma la transformación matemática:

1. PC1 (Componente de Conservantes): Está fuertemente dominada por el dióxido de azufre (libre y total). El PCA ha identificado matemáticamente la correlación (+0.72) que detectamos en el EDA y ha fusionado toda esa información redundante sobre conservantes en un único vector.

2. PC2 (Componente de Cuerpo y Grado): Está dominada positivamente por la densidad (+0.56) y negativamente por el alcohol (-0.47). Captura la relación inversa del vino (a más alcohol, menos densidad) y la empaqueta en una sola dimensión independiente.

5.3. Transformación Definitiva al Espacio Reducido

Proyectamos el dataset original estandarizado (12 dimensiones) sobre las 9 componentes seleccionadas para crear nuestra matriz de datos final.

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	quality
0	-3.267418	-0.132454	-2.678852	-0.792389	-0.078486	-0.388374	-0.524146	-0.179956	-0.099497	5
1	-3.183220	0.604973	-1.980682	-0.768958	1.195426	1.650779	-0.701325	0.108239	0.353585	5
2	-3.187813	0.364465	-1.685740	-0.789422	0.732714	0.824151	-0.480104	0.228400	0.213520	5
3	-1.939949	1.893499	2.505797	-0.376310	-0.528600	-0.991847	-0.921516	-0.696503	-0.519432	6
4	-3.078987	-0.122115	-2.630865	-0.682017	-0.080671	-0.458331	-0.594726	-0.135261	-0.215659	5

Figura 12. Transformación de las variables al espacio reducido por el PCA.

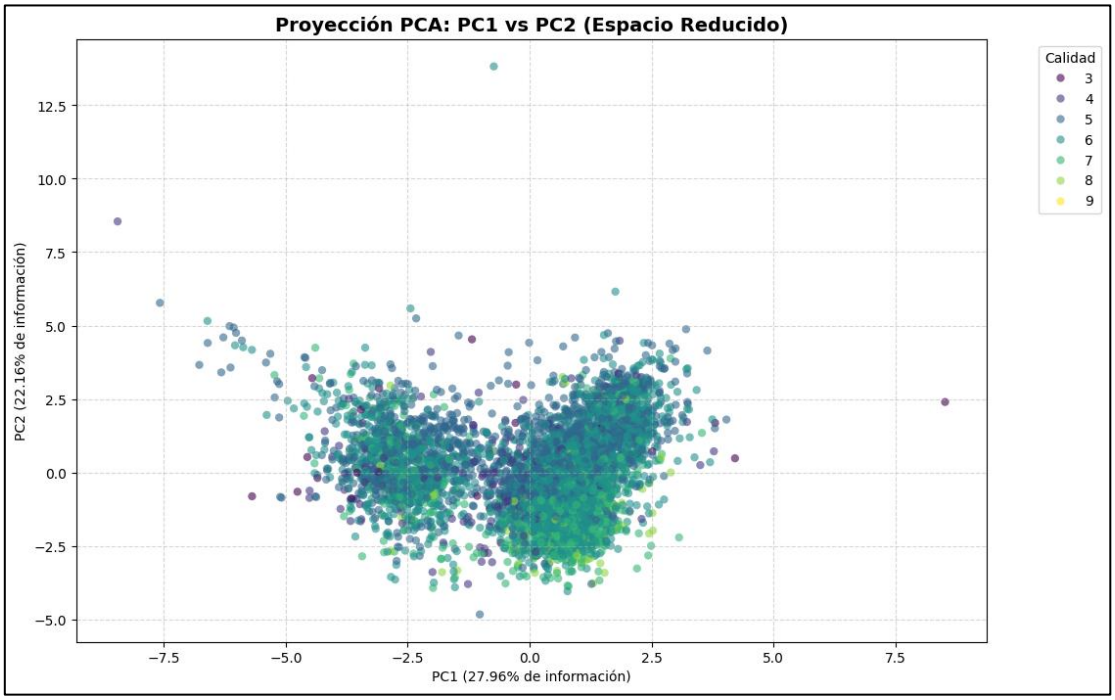

Figura 13. Proyección 2D del dataset sobre las dos Componentes Principales con mayor varianza.

De esta transformación definitiva, destacamos las tres ventajas operativas con las que entraremos a la fase de modelado:

1. Compresión Eficiente: Hemos sustituido la matriz original por 9 columnas abstractas de información compacta.

2. Eliminación Total de Colinealidad: Por definición matemática, los vectores del PCA (PC1 a PC9) son completamente ortogonales. Al forzar una correlación exacta de 0.00 entre las nuevas variables, eliminamos la redundancia informativa, adaptando el dataset para que algoritmos probabilísticos como el *Naïve Bayes* puedan funcionar sin violar sus suposiciones teóricas.

3. Mezcla Visual: La proyección 2D muestra una "nube" densa donde los colores (calidades) están profundamente solapados. Esto demuestra visualmente que el problema no es linealmente separable en baja dimensión. Un humano no puede trazar una línea para separar los vinos buenos de los malos, lo que justifica la necesidad de entrenar modelos algorítmicos.

6. Modelado Predictivo y Clasificación

En esta fase final, utilizamos el dataset optimizado para entrenar a la Inteligencia Artificial. El reto es predecir la nota de calidad del vino utilizando dos algoritmos probabilísticos: **Linear Discriminant Analysis (LDA)** y **Gaussian Naïve Bayes (NB)**.

6.1. Metodología de Entrenamiento y Evaluación

Para garantizar que el test evalúa con fiabilidad el entreno del modelo, los modelos no se evalúan con los mismos datos con los que aprenden. Hemos diseñado dos estrategias de validación:

1. **Entreno único estratificado (80/20):** Separamos un 20% de los datos para el examen final. Al hacerlo estratificado Con esto forzamos que ese 20% de test mantenga exactamente la misma proporción de vinos buenos y malos que el dataset original.
2. **Validación Cruzada (5-Fold Cross-Validation):** Hacemos que el modelo realice 5 test distintos rotando los datos de prueba hasta evaluar el 100% del dataset. Un único corte 80/20 puede darnos resultados sesgados por la forma de repartir los vinos entre el train y el test. El *Cross-Validation* nos da esa precisión matemática al tener varios test.

6.2. Modelo con PCA (Entreno único 80/20)

Entrenamos los modelos con las 9 Componentes Principales y los evaluamos sobre el 20% reservado.

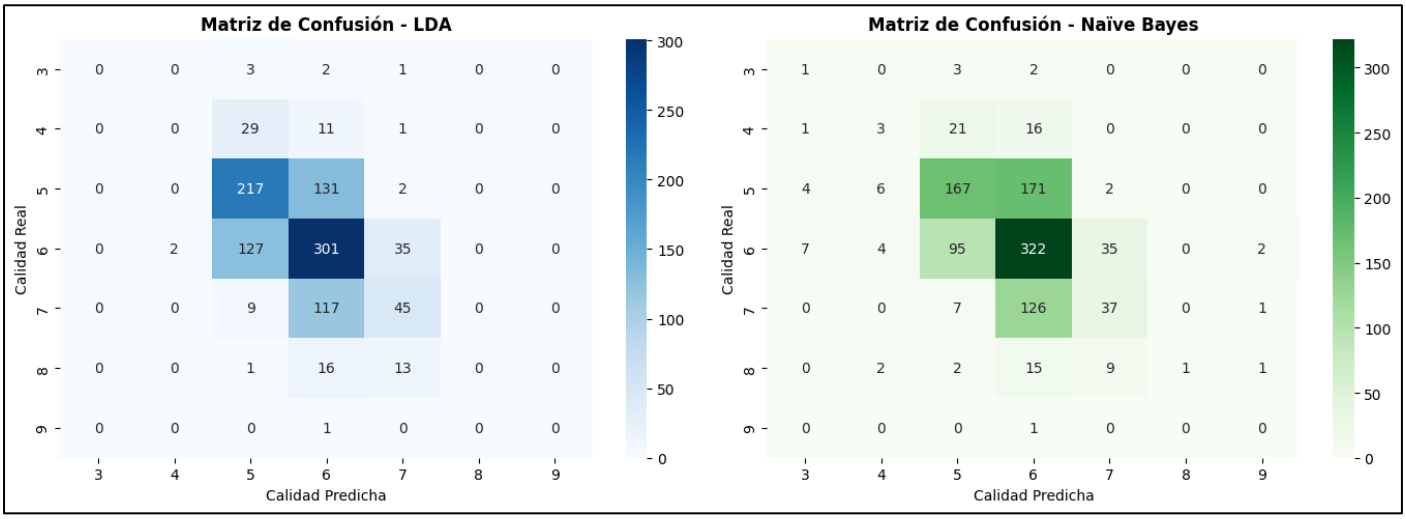

Figura 14. Matrices de Confusión (Entreno único 80/20) con PCA

```
--- REPORTE DETALLADO: LINEAR DISCRIMINANT ANALYSIS (LDA) ---
              precision    recall  f1-score   support

           3       0.00      0.00      0.00         6
           4       0.00      0.00      0.00        41
           5       0.56      0.62      0.59       350
           6       0.52      0.65      0.58       465
           7       0.46      0.26      0.34       171
           8       0.00      0.00      0.00        30
           9       0.00      0.00      0.00         1

    accuracy                           0.53      1064
   macro avg       0.22      0.22      0.21      1064
weighted avg       0.49      0.53      0.50      1064

--- REPORTE DETALLADO: NAÏVE BAYES ---
              precision    recall  f1-score   support

           3       0.08      0.17      0.11         6
           4       0.20      0.07      0.11        41
           5       0.57      0.48      0.52       350
           6       0.49      0.69      0.58       465
           7       0.45      0.22      0.29       171
           8       1.00      0.03      0.06        30
           9       0.00      0.00      0.00         1

    accuracy                           0.50      1064
   macro avg       0.40      0.24      0.24      1064
weighted avg       0.51      0.50      0.48      1064
```

Figura 15. Estadísticas (Entreno único 80/20) con PCA

(Métricas obtenidas -> LDA: 53% Accuracy | NB: 50% Accuracy)

1. El Espejismo de la Precisión Global (Accuracy): A primera vista, el LDA (**52.91%**) supera al Naïve Bayes (**49.91%**). Sin embargo, si observamos la distribución del test, 815 de las 1064 muestras (el 76%) pertenecen a las calidades 5 y 6. Las matrices revelan que el LDA ha optado por predecir masivamente cincos y seises. El grueso de sus aciertos se concentra en la diagonal central (**217 aciertos para la clase 5 y 301 para la clase 6**), inflando el Accuracy global pero sin hacer una predicción equilibrada.

2. Colapso Total en Clases Minoritarias (LDA): El reporte detallado del LDA nos dice que para las calidades extremas (3, 4, 8 y 9), la precisión, el recall y el f1-score caen a **0.00**. Observando la matriz en las filas de calidad real 4 y 8, vemos que el modelo predice sistemáticamente que son vinos medios. La varianza retenida por el PCA no ha sido suficiente para que un modelo lineal dibuje fronteras que aíslen estos casos atípicos.

3. El Comportamiento Errático de Naïve Bayes: Aunque obtiene un Accuracy menor, su comportamiento genera anomalías en los extremos:

- **En la clase 8:** Muestra una precisión perfecta (**1.00**) pero un recall de **0.03**. El modelo es extremadamente cauteloso: solo se arriesgó a predecir un "8" una única vez (y acertó), fallando en los otros 29 vinos excelentes.
- **En la clase 3:** Alcanza un recall de **0.17** (logró identificar 1 de los 6 vinos de calidad 3), pero a costa de disparar múltiples falsos positivos, lo que sitúa su precisión en un **0.08**.

6.3. Validación Cruzada con PCA (5-Folds)

Para confirmar que el colapso anterior no fue un sesgo aleatorio provocado por un corte de datos "difícil", sometemos a los modelos a una Validación Cruzada sobre la totalidad del dataset (5,320 muestras).

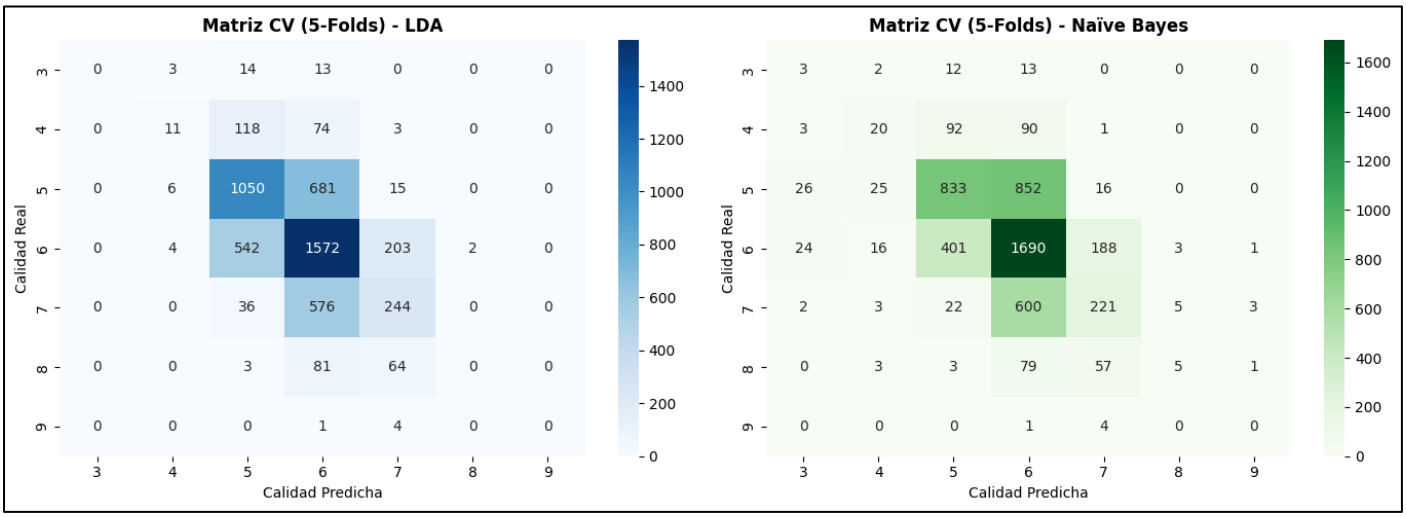

Figura 16. Matrices de Confusión Global (5-Folds Cross-Validation) con PCA

```
--- REPORTE CROSS-VALIDATION (5-Folds): LDA ---
              precision    recall  f1-score   support

           3       0.00      0.00      0.00        30
           4       0.46      0.05      0.10       206
           5       0.60      0.60      0.60      1752
           6       0.52      0.68      0.59      2323
           7       0.46      0.29      0.35       856
           8       0.00      0.00      0.00       148
           9       0.00      0.00      0.00         5

    accuracy                           0.54      5320
   macro avg       0.29      0.23      0.23      5320
weighted avg       0.52      0.54      0.51      5320

--- REPORTE CROSS-VALIDATION (5-Folds): NAÏVE BAYES ---
              precision    recall  f1-score   support

           3       0.05      0.10      0.07        30
           4       0.29      0.10      0.15       206
           5       0.61      0.48      0.53      1752
           6       0.51      0.73      0.60      2323
           7       0.45      0.26      0.33       856
           8       0.38      0.03      0.06       148
           9       0.00      0.00      0.00         5
...
    accuracy                           0.52      5320
   macro avg       0.33      0.24      0.25      5320
weighted avg       0.52      0.52      0.50      5320
```

Figura 17. Estadísticas (5-Folds Cross-Validation) con PCA

El análisis de esta validación cruzada confirma que nos enfrentamos a una limitación estructural:

1. Consolidación de la Precisión Engañosa: El *Accuracy* medio se estabiliza en un 54% para LDA y un 52% para Naïve Bayes. La matriz global del LDA muestra que, de sus 2,876 aciertos totales, más de la mitad (1,569) provienen exclusivamente de predecir la clase 6, ratificando el sesgo hacia la clase mayoritaria.

2. Fracaso Absoluto en Vinos de Alta Calidad: El dato más crítico lo revela la clase 8. Teniendo un soporte total de 148 vinos excelentes, el modelo LDA es completamente ciego a ellos (*Recall* de 0.00), clasificándolos como seises o sietes. El modelo Naïve Bayes apenas logra un *Recall* de 0.03, identificando solo 5 de esos 148 vinos.

6.4. Evaluación de Modelos con el Dataset Original (Entreno único 80/20)

Para comprobar si esta incapacidad predictiva fue provocada al descartar el 5% de la información original durante el PCA, repetimos el entrenamiento utilizando el conjunto de características químicas originales estandarizadas.

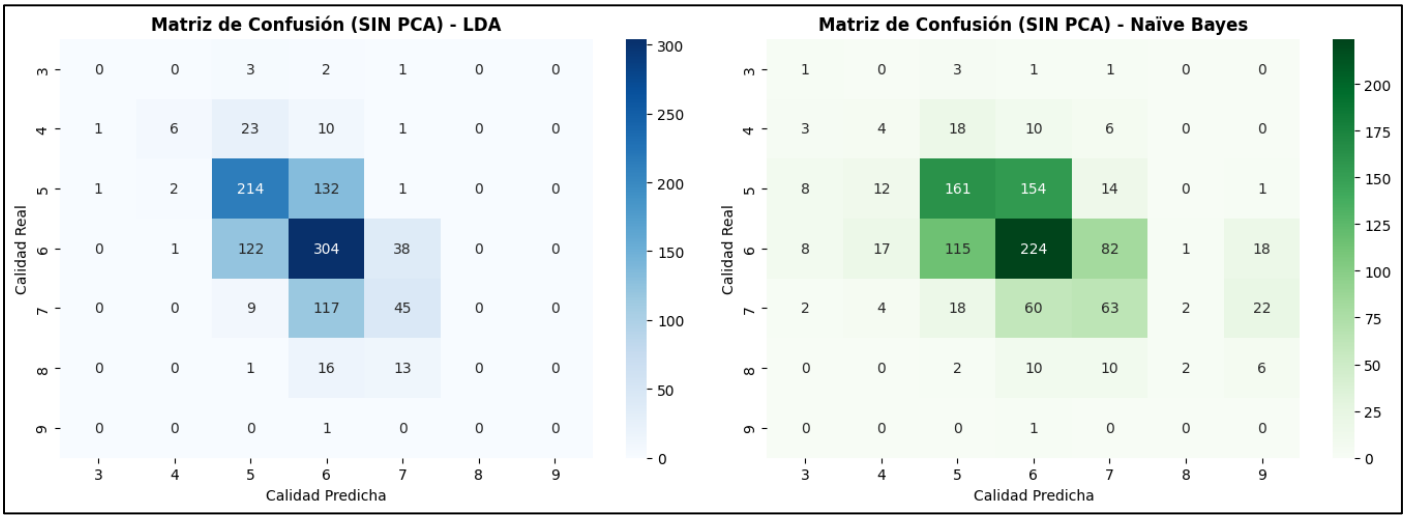

Figura 18. Matriz de Confusión (Entreno único) utilizando variables químicas originales.

```
--- REPORTE DETALLADO (SIN PCA): LDA ---
              precision    recall  f1-score   support

           3       0.00      0.00      0.00         6
           4       0.67      0.15      0.24        41
           5       0.58      0.61      0.59       350
           6       0.52      0.65      0.58       465
           7       0.45      0.26      0.33       171
           8       0.00      0.00      0.00        30
           9       0.00      0.00      0.00         1

    accuracy                           0.53      1064
   macro avg       0.32      0.24      0.25      1064
weighted avg       0.52      0.53      0.51      1064

--- REPORTE DETALLADO (SIN PCA): NAÏVE BAYES ---
              precision    recall  f1-score   support

           3       0.05      0.17      0.07         6
           4       0.11      0.10      0.10        41
           5       0.51      0.46      0.48       350
           6       0.49      0.48      0.48       465
           7       0.36      0.37      0.36       171
           8       0.40      0.07      0.11        30
           9       0.00      0.00      0.00         1
...
    accuracy                           0.43      1064
   macro avg       0.27      0.23      0.23      1064
weighted avg       0.45      0.43      0.44      1064
```

Figura 19. Estadísticas (Entreno único) utilizando variables químicas originales.

Los resultados de este experimento demuestran lo contrario:

1. **El LDA sigue ciego al desbalanceo:** A pesar de tener acceso a todas las características originales, el LDA mantiene su precisión global en un **53%** (prácticamente idéntica al **52.91%** obtenida con PCA) y sigue fracasando totalmente en los extremos (recall de **0.00** para las clases 3, 8 y 9). El modelo lineal no es capaz de trazar una frontera que aísle un vino excelente, sin importar si usa componentes principales o variables químicas puras.
2. **Naïve Bayes empeora con la colinealidad:** Su precisión global cae del **50%** (con PCA) al **43%** (sin PCA). Como vimos en el EDA, variables como el alcohol y la densidad tienen una fuerte correlación. El algoritmo Naïve Bayes asume que todas las variables son 100% independientes; al quitarle el PCA (que eliminaba esta colinealidad), el modelo se "confunde" por la información redundante, justificando esta bajada de rendimiento.

6.5. Evaluación de Modelos con el Dataset Original (5-Fold Cross-Validation)

Para dar por concluido el experimento con el máximo rigor estadístico, someteremos los modelos a una Validación Cruzada Estratificada (5-Folds) utilizando todas las características químicas originales

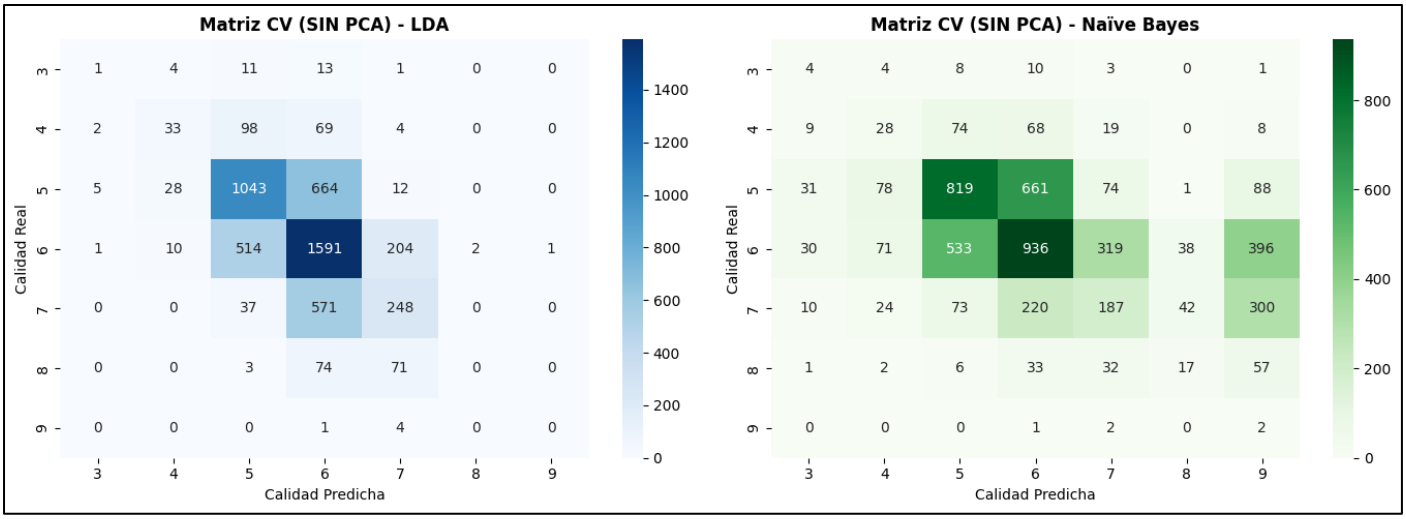

Figura 20. Matriz de Confusión (5 Fold Cross-Validation) utilizando variables químicas originales.

```
--- REPORTE CV (5-Folds) SIN PCA: LINEAR DISCRIMINANT ANALYSIS ---
              precision    recall  f1-score   support

           3       0.11      0.03      0.05        30
           4       0.44      0.16      0.23       206
           5       0.61      0.60      0.60      1752
           6       0.53      0.68      0.60      2323
           7       0.46      0.29      0.35       856
           8       0.00      0.00      0.00       148
           9       0.00      0.00      0.00         5

    accuracy                           0.55      5320
   macro avg       0.31      0.25      0.26      5320
weighted avg       0.53      0.55      0.53      5320

--- REPORTE CV (5-Folds) SIN PCA: NAÏVE BAYES ---
              precision    recall  f1-score   support

           3       0.05      0.13      0.07        30
           4       0.14      0.14      0.14       206
           5       0.54      0.47      0.50      1752
           6       0.49      0.40      0.44      2323
           7       0.29      0.22      0.25       856
           8       0.17      0.11      0.14       148
           9       0.00      0.40      0.00         5
...
    accuracy                           0.37      5320
   macro avg       0.24      0.27      0.22      5320
weighted avg       0.45      0.37      0.41      5320
```

Figura 21. Estadísticas (5 Fold Cross-Validation) utilizando variables químicas originales.

Aquí podemos observar que la validación cruzada ha demostrado el inmenso beneficio del PCA sobre el modelo Naïve Bayes. Al utilizar los datos originales, su *Accuracy* se desploma del 51% al **37%.**

7. Tratamiento del Desbalanceo (SMOTE)

Debido a que los modelos anteriores ignoraban las clases minoritarias, se aplica la técnica **SMOTE** (Synthetic Minority Over-sampling Technique). Este método genera datos sintéticos para las calidades 3, 4, 8 y 9, equilibrando el dataset para que el modelo tenga suficientes ejemplos de cada categoría antes de entrenar.

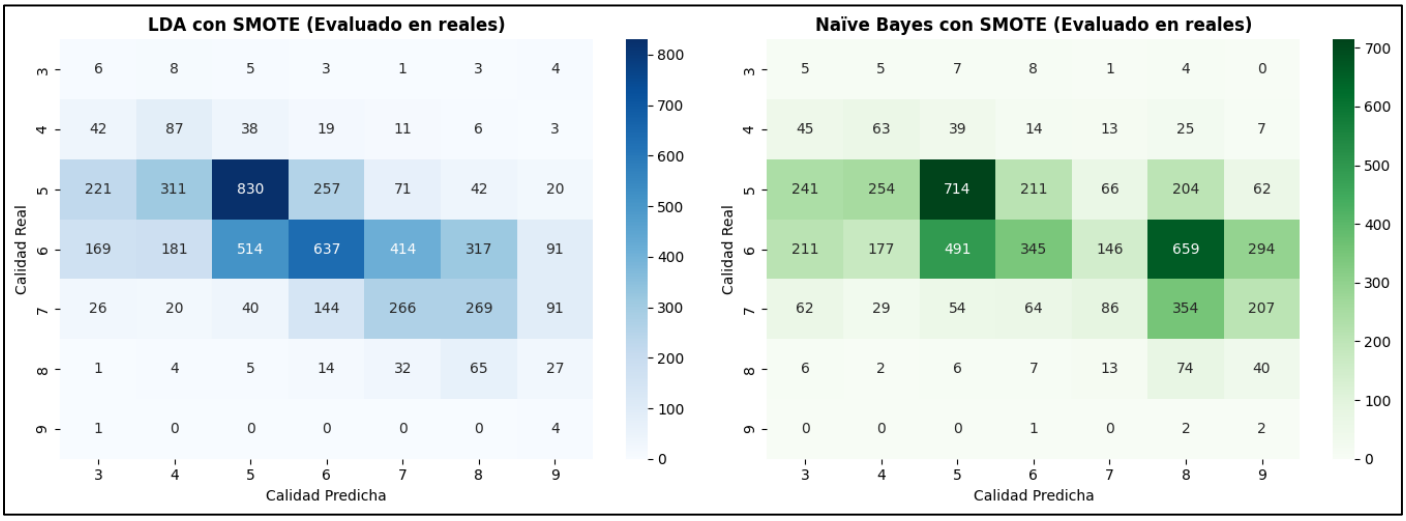

Figura 22. Matriz de Confusión (SMOTE) utilizando variables químicas originales.

```
ACCURACY LDA + SMOTE: 35.62%
ACCURACY NAÏVE BAYES + SMOTE: 24.23%

--- REPORTE LDA ---
              precision    recall  f1-score   support

           3       0.01      0.20      0.02        30
           4       0.14      0.42      0.21       206
           5       0.58      0.47      0.52      1752
           6       0.59      0.27      0.38      2323
           7       0.33      0.31      0.32       856
           8       0.09      0.44      0.15       148
           9       0.02      0.80      0.03         5

    accuracy                           0.36      5320
   macro avg       0.25      0.42      0.23      5320
weighted avg       0.51      0.36      0.40      5320

--- REPORTE NAÏVE BAYES ---
              precision    recall  f1-score   support

           3       0.01      0.17      0.02        30
           4       0.12      0.31      0.17       206
           5       0.54      0.41      0.47      1752
           6       0.53      0.15      0.23      2323
...
    accuracy                           0.24      5320
   macro avg       0.22      0.29      0.16      5320
weighted avg       0.46      0.24      0.29      5320
```

Figura 23. Estadísticas (SMOTE) utilizando variables químicas originales.

Los resultados obtenidos tras aplicar la validación cruzada revelan una degradación severa en el rendimiento de ambos algoritmos. La precisión global (*Accuracy*) se desploma a un **36% para el modelo LDA** y a un **24% para el Naïve Bayes**.

Al analizar las métricas en detalle y las matrices de confusión, se extraen las siguientes conclusiones:

- **Falsos positivos masivos:** Aunque el sobremuestreo logra que los algoritmos detecten las clases minoritarias (ej. el LDA obtiene un *recall* de 0.80 en la clase 9), lo hace a costa de predecir estas clases de forma descontrolada. La precisión (*precision*) en los extremos cae casi a cero (0.02), lo que indica que el modelo no ha aprendido a distinguir la calidad, sino que simplemente dispara etiquetas extremas al azar influenciado por los datos sintéticos.
- **Generación de ruido químico:** La interpolación matemática que realiza SMOTE para inventar datos asume linealidad. Sin embargo, en un problema fisicoquímico real, mezclar variables de dos vinos no genera un vino válido, sino "ruido". Este ruido destruye las fronteras de decisión rectas que necesita el LDA.
- **Colapso del Naïve Bayes:** La inyección masiva de datos sintéticos crea una fuerte correlación artificial entre las variables químicas, rompiendo por completo la asunción de independencia que exige el Teorema de Bayes.

Queda demostrado empíricamente que la generación de datos sintéticos (SMOTE) no es una estrategia viable para datos fisicoquímicos. Para resolver este problema se podría optar por algoritmos no lineales (como Random Forest) combinados con la penalización asimétrica de errores.

8. Conclusión General del Proyecto

Tras completar todas las fases del análisis, desde el preprocesamiento hasta el tratamiento del desbalanceo, se extraen las siguientes conclusiones definitivas:

1. Éxito de la Reducción de Dimensionalidad (PCA): El rendimiento del modelo LDA se mantuvo prácticamente idéntico (**55% de Accuracy** en Validación Cruzada sin PCA vs. **54% con PCA**). Esto demuestra que la compresión de variables fue un éxito: logramos la misma capacidad predictiva utilizando menos recursos computacionales, confirmando que el 5% de varianza descartado no era determinante para el problema.

2. El PCA como "Salvavidas" de Naïve Bayes: La validación cruzada confirmó que el PCA es imprescindible para este modelo. Al usar los datos originales, el Accuracy de Naïve Bayes se desplomó al **37%**. Este colapso se debe a la **colinealidad** química (correlación entre alcohol, densidad y azúcares), que viola la asunción de independencia del modelo. El PCA resolvió este problema de forma nativa al crear componentes independientes.

3. Lecciones del SMOTE y el Desbalanceo: El experimento con SMOTE demostró que el problema del dataset no es solo la falta de ejemplos, sino el **solapamiento químico**. Aunque el SMOTE permitió que los modelos detectaran clases minoritarias, introdujo una cantidad inasumible de **ruido y falsos positivos**. Se concluye que las clases no están separadas de forma lineal; los perfiles químicos de un vino de calidad 5 y uno de calidad 8 están demasiado mezclados para un discriminante lineal.

Recomendaciones y Trabajo Futuro

Para superar la barrera del 55% de precisión y construir un sistema de certificación fiable, el trabajo futuro debe centrarse en:

- **Transición a Modelos No Lineales:** El paso evolutivo necesario es abandonar la rigidez del LDA y el Naïve Bayes. Algoritmos como **Random Forest** son más aptos, ya que no asumen distribuciones gaussianas y gestionan mejor el solapamiento de clases.
- **Ampliación del Dataset Real:** El SMOTE ha demostrado ser un parche limitado. Es prioritario obtener más muestras reales de calidades 3, 4, 8 y 9. Para aplicar modelos avanzados como el **QDA (Análisis Discriminante Cuadrático)**, necesitamos superar el límite geométrico de muestras por clase para evitar el colapso de las matrices de covarianza.
- **Características:** Investigar si nuevas variables (como polifenoles o datos sensoriales adicionales) pueden ayudar a separar mejor las calidades en el espacio multidimensional.